Metodología del proyecto:

Clasificación de variedades de frijol seco con una red neuronal cuántica de *data re-uploading*

Computación Cuántica – Proyecto Final (Opción 1: Clasificación de Semillas)
Prof. Naomi Itzel Reyes Granados | Ayud. Sebastián González Juárez

Entrega: 7 de diciembre de 2026

Resumen

Este documento describe de forma detallada y justificada la metodología seguida en el proyecto: el planteamiento del problema, el tratamiento de los datos (incluyendo las medidas contra la fuga de información), el fundamento teórico del clasificador cuántico variacional elegido (*data re-uploading*), su implementación híbrida cuántico-clásica, el diseño experimental y la forma de evaluar y comparar contra modelos clásicos. Se incluyen las decisiones de diseño y su justificación, así como las limitaciones. Todo el código y los resultados reproducibles se encuentran en el cuaderno `Proyecto_Final_Semillas_QML.ipynb`.

Índice

1. Planteamiento del problema **2**
1.1. Contexto (narrativa) . . . 2
1.2. Pregunta de investigación y objetivos . . . 2
1.3. Formalización . . . 2

2. Datos **3**

3. Preprocesamiento sin fuga de información **3**

4. Fundamento teórico del modelo cuántico **4**
4.1. Clasificadores variacionales y el límite de codificar una sola vez . . . 4
4.2. Arquitectura *data re-uploading* . . . 4
4.3. ¿Por qué resuelve el problema? (argumento de expresividad) . . . 5
4.4. Lectura multiclase y función de pérdida . . . 5
4.5. Optimización . . . 6

5. Implementación **6**
5.1. Pila de software y justificación . . . 6
5.2. Verificación del circuito . . . 6
5.3. Decisiones de diseño relevantes . . . 6

6. Diseño experimental y métricas **7**

7. Resultados **7**
7.1. Modelo cuántico 7
7.2. Comparación con modelos clásicos 8
7.3. Ablaciones 9
7.4. Efecto del número de *shots* y costo 9

8. Discusión y conclusiones **10**

9. Reproducibilidad **10**

1. Planteamiento del problema

1.1. Contexto (narrativa)

Una cooperativa agrícola y centro de acopio de leguminosas recibe a diario toneladas de frijol de distintos productores. El precio, las condiciones de almacenamiento y la certificación de semilla dependen de la *variedad*, y mezclar variedades (impureza varietal) puede inutilizar un lote completo. La clasificación manual por personal experto es lenta, subjetiva y cansada.

El centro cuenta con una banda transportadora con cámara que, mediante visión por computadora, extrae para cada grano 16 medidas morfológicas (área, perímetro, longitudes de los ejes, factores de forma, etc.). El problema consiste en **decidir, a partir de esas medidas, a cuál de siete variedades pertenece cada grano**: Barbunya, Bombay, Cali, Dermason, Horoz, Seker y Sira.

1.2. Pregunta de investigación y objetivos

> *¿Puede un clasificador variacional cuántico de muy pocos qubits y parámetros competir con modelos clásicos de tamaño comparable en este problema multiclase real, y qué se gana o se pierde al hacerlo?*

Objetivos específicos: (i) formalizar el problema; (ii) diseñar un preprocesamiento sin fuga de información y compatible con la codificación cuántica; (iii) implementar y entrenar una QNN de *data re-uploading*; (iv) compararla con baselines clásicos usando métricas adecuadas (*accuracy*, F1 macro, matriz de confusión); (v) analizar la influencia de la arquitectura (ablaciones) y del muestreo finito (*shots*), y discutir con honestidad la existencia o no de ventaja cuántica.

1.3. Formalización

Sea $\mathcal{D} = \{(\boldsymbol{x}_i, y_i)\}_{i=1}^{N}$, con $\boldsymbol{x}_i \in \mathbb{R}^{16}$ y $y_i \in \{0, \dots, 6\}$. Se busca un clasificador probabilístico $f_{\boldsymbol{\theta}} : \mathbb{R}^d \to \Delta^6$ (símplex de probabilidades sobre las 7 clases) que minimice la entropía cruzada empírica

$$\mathcal{L}(\boldsymbol{\theta}) = -\frac{1}{N}\sum_{i=1}^{N} \log\left[f_{\boldsymbol{\theta}}(\boldsymbol{x}_i)\right]_{y_i}, \qquad \hat{y}(\boldsymbol{x}) = \arg\max_{k} \left[f_{\boldsymbol{\theta}}(\boldsymbol{x})\right]_k. \tag{1}$$

La entropía cruzada es la log-verosimilitud negativa de un modelo categórico; es diferenciable, y su minimización con modelos suficientemente expresivos aproxima las probabilidades condicionales $P(y \mid \boldsymbol{x})$. Dado que $\boldsymbol{\theta}$ incluye ángulos de rotaciones, el problema de optimización es **no convexo**, por lo que el resultado depende de la inicialización y se mide con varias semillas.

2. Datos

Se usa el conjunto *Dry Bean* del repositorio UCI [1]: 13 611 granos de siete variedades, fotografiados y segmentados, con 16 características: 12 dimensiones/geometrías (área, perímetro, longitud del eje mayor y menor, razón de aspecto, excentricidad, área convexa, diámetro equivalente, *extent*, *solidity*, *roundness*, *compactness*) y 4 factores de forma.

Calidad de datos. No hay valores nulos. Se detectaron **68 filas duplicadas exactas** que se eliminaron (quedan 13 543 granos): un grano repetido que cayera en entrenamiento y prueba a la vez inflaría artificialmente el desempeño (fuga de información).

Desbalance. La clase mayoritaria (Dermason, $\approx 26\,\%$) es unas siete veces más frecuente que la minoritaria (Bombay, $\approx 4\,\%$). Por ello se usa partición *estratificada* y se reporta F1 macro además de *accuracy*.

Redundancia. Hay 15 pares de características con $|\rho| > 0{,}95$ (área, perímetro, ejes, diámetro equivalente, área convexa…). Esto motiva la reducción de dimensionalidad.

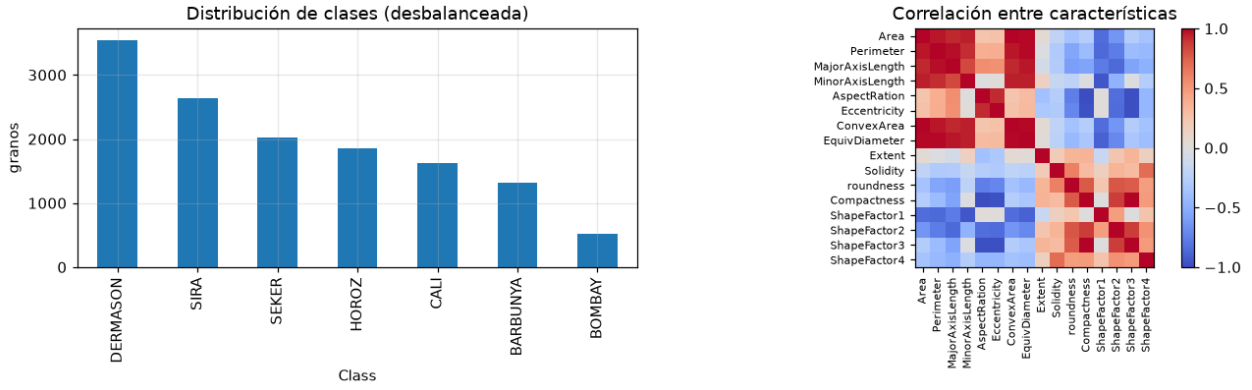


Figura 1: Izquierda: distribución de clases. Derecha: matriz de correlación; los bloques rojos indican fuerte redundancia entre características.

3. Preprocesamiento sin fuga de información

La codificación cuántica impone dos restricciones: (a) con *codificación por ángulos* se usa un qubit por característica, y el costo de simular o ejecutar el circuito crece rápidamente con el número de qubits; (b) los datos deben transformarse a ángulos en un intervalo acotado. El pipeline es el siguiente y **todos sus parámetros se ajustan únicamente con el conjunto de entrenamiento**:

1. **Partición estratificada.** 70 % entrenamiento / 30 % prueba (4 063 granos); del entrenamiento se aparta 10 % como *validación* (948 granos) para elegir la mejor época. El conjunto de prueba se usa una sola vez al final. Resultan 8 532 / 948 / 4 063 granos.

2. **Estandarización** (media 0, varianza 1). Es indispensable antes de PCA, pues las características tienen escalas muy diferentes (área $\sim 10^5$ frente a razones ~ 1).

3. **PCA a 4 componentes** (uno por qubit), que retiene aprox. 95 % de la varianza (Figura 2). Se ajusta con train y se aplica a validación y prueba.

4. **Escalado a** $[0, \pi]$ con min–max (ajustado en train). Como $R_X(\alpha x)$ es 2π-periódica en el ángulo, el rango $[0, \pi]$ mantiene una correspondencia inyectiva entre valores y estados en la esfera de Bloch (con $[0, 2\pi]$ los extremos coincidirían). En validación y prueba algunos valores pueden salir ligeramente del rango, lo que es esperable.

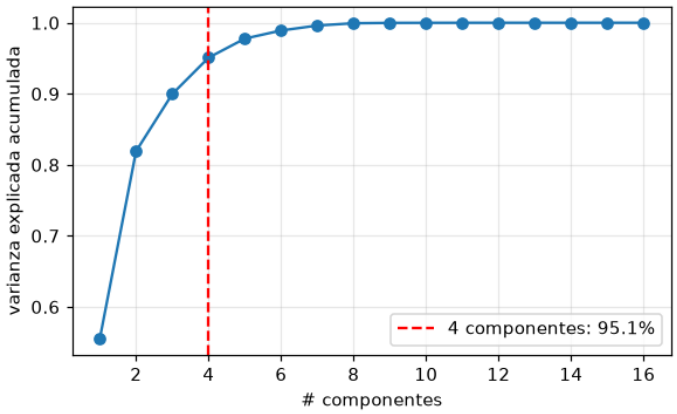


Figura 2: Varianza explicada acumulada (PCA ajustado en train). Con 4 componentes se conserva $\approx 95\,\%$.

Justificación de la compresión. Reducir de 16 a 4 características *pierde* algo de información discriminante; este costo se cuantifica explícitamente al comparar con modelos clásicos que sí usan las 16 características (Sección 7).

4. Fundamento teórico del modelo cuántico

4.1. Clasificadores variacionales y el límite de codificar una sola vez

Un modelo cuántico variacional evalúa $f(\boldsymbol{x}) = \langle 0| U^\dagger(\boldsymbol{x}, \boldsymbol{\theta})\, M\, U(\boldsymbol{x}, \boldsymbol{\theta}) |0\rangle$ con un circuito U parametrizado y una medición M. Schuld, Sweke y Meyer [3] probaron que, si el dato se codifica con puertas de la forma $e^{-ixH/2}$, el modelo es una **serie de Fourier truncada** en $\boldsymbol{x}$:

$$f_{\boldsymbol{\theta}}(x) = \sum_{\omega \in \Omega} c_\omega(\boldsymbol{\theta})\, e^{i\omega x}, \tag{2}$$

donde el espectro Ω queda determinado únicamente por la codificación (los valores propios del generador), mientras que los coeficientes c_ω son los que se entrenan. Con una sola subida de $R_X(x)$ por qubit solo hay frecuencias $\omega \in \{-1, 0, 1\}$: el modelo es poco expresivo. Si se codifica L veces, $\Omega = \{-L, \ldots, L\}$.

4.2. Arquitectura *data re-uploading*

La idea de Pérez-Salinas et al. [2] es intercalar L veces *codificación* y *bloques entrenables*:

$$U_{\boldsymbol{\theta}}(\boldsymbol{x}) = \prod_{l=L}^{1} \Big[W_l(\boldsymbol{\theta}_l)\, S_l(\boldsymbol{x}; \boldsymbol{\alpha}_l) \Big], \qquad |\psi(\boldsymbol{x})\rangle = U_{\boldsymbol{\theta}}(\boldsymbol{x})\, |0\rangle^{\otimes n}, \tag{3}$$

$$S_l(\boldsymbol{x};\boldsymbol{\alpha}_l) = \bigotimes_{q=1}^{n} R_X(\alpha_{l,q}\, x_q), \tag{4}$$

$$W_l(\boldsymbol{\theta}_l) = \underbrace{\mathrm{CNOT}_{n\to 1}\cdots\mathrm{CNOT}_{2\to 3}\,\mathrm{CNOT}_{1\to 2}}_{\text{anillo de entrelazamiento}} \bigotimes_{q=1}^{n} \mathrm{Rot}(\phi_{l,q},\vartheta_{l,q},\omega_{l,q}), \tag{5}$$

con $\mathrm{Rot}(\phi,\vartheta,\omega) = R_Z(\omega)R_Y(\vartheta)R_Z(\phi)$, una rotación genérica en SU(2). Los $\alpha_{l,q}$ son **pesos de escala entrenables**, el análogo de $w \cdot x$ en una neurona: reescalan los datos y, con ello, los anchos de banda del modelo de Fourier.

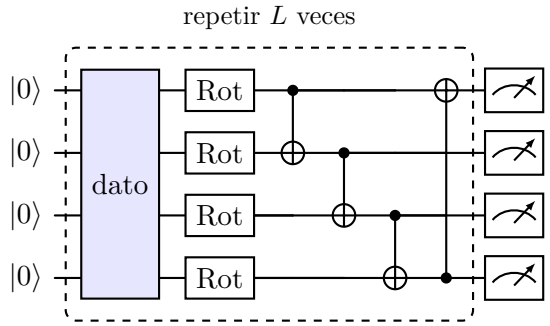


Figura 3: Una capa del circuito ($n = 4$). El bloque "dato" aplica $R_X(\alpha_{l,q}x_q)$ en cada qubit q; después, una rotación Rot entrenable por qubit y CNOTs en anillo. Esta capa se repite L veces (modelo principal: $L = 4$) y al final se miden las probabilidades de los estados base.

4.3. ¿Por qué resuelve el problema? (argumento de expresividad)

1. **Frecuencias.** Cada re-subida amplía el espectro de frecuencias accesible (hasta $\pm L$ por característica), de modo que el modelo puede representar fronteras de decisión cada vez más complejas (Sección anterior).

2. **Mezcla de características.** Los CNOT crean entrelazamiento, de manera que las amplitudes finales dependen de *productos* de funciones trigonométricas de distintas características, no solo de sumas; es el análogo de las capas ocultas.

3. **Universalidad.** Pérez-Salinas et al. [2] y Schuld et al. [3] demuestran que, con suficientes capas, esta familia puede aproximar cualquier función continua acotada (aproximador universal), igual que un MLP con capa oculta ancha.

4. **Geometría.** Cada capa "dobla" el espacio de entrada sobre una trayectoria en el espacio de Hilbert; la clasificación consiste en que las trayectorias de muestras de la misma clase terminen cerca del mismo estado base.

La universalidad garantiza *existencia*, no *capacidad de aprenderlo* con un optimizador local en un paisaje no convexo; por eso la evidencia empírica (ablaciones, Sección 7.3) es parte esencial de la justificación.

4.4. Lectura multiclase y función de pérdida

Con $n = 4$ qubits hay $2^4 = 16$ estados base. Se asocia la clase k al estado $|k\rangle$ ($k = 0,\ldots,6$), y se definen

$$p_k(\boldsymbol{x}) = \left|\,\langle k|\psi(\boldsymbol{x})\rangle\,\right|^2, \qquad f_{\boldsymbol{\theta}}(\boldsymbol{x})_k = \mathrm{softmax}_k\left(\beta\, p_k(\boldsymbol{x})\right) = \frac{e^{\beta p_k}}{\sum_{j=0}^{6} e^{\beta p_j}}. \tag{6}$$

La temperatura $\beta > 0$ es *entrenable*: como $p_k \in [0,1]$, sin ella el *softmax* sería casi uniforme y la entropía cruzada (1) no podría hacerse pequeña. Los 9 estados base restantes actúan como "desagüe" de probabilidad. El número total de parámetros es

$$|\boldsymbol{\theta}| = \underbrace{3nL}_{\text{Rot}} + \underbrace{nL}_{\alpha} + \underbrace{1}_{\beta} = 4nL + 1 \quad \Rightarrow \quad 65 \text{ para } n = 4,\ L = 4. \tag{7}$$

4.5. Optimización

Se minimiza la entropía cruzada por descenso estocástico con **Adam** (tasa inicial 0,05, decaimiento coseno, *minibatch* de 128, 20 épocas). Los ángulos se inicializan uniformemente en $[0, 2\pi)$, $\alpha_{l,q} = 1$ y $\beta = 10$. Los gradientes se obtienen por *backpropagation* sobre el simulador de vector de estado, eficiente en simulación. En un dispositivo real se usaría la regla de desplazamiento de parámetros (*parameter-shift*), $\partial_\theta f = \frac{1}{2}[f(\theta + \pi/2) - f(\theta - \pi/2)]$, que cuesta dos evaluaciones del circuito por parámetro y por muestra (Sección 7.4).

5. Implementación

5.1. Pila de software y justificación

Librería	Uso y justificación
`numpy`, `pandas`, `matplotlib`	Manejo de datos y gráficas (estándar).
`scikit-learn`	Partición estratificada, estandarización, PCA, métricas y modelos clásicos de referencia; evita reimplementar piezas bien probadas y garantiza una comparación justa.
`pennylane`	Definición del circuito y diferenciación automática. Su *parameter broadcasting* evalúa todo un *minibatch* en una sola ejecución del circuito, lo que reduce el entrenamiento de horas a minutos.
`qiskit`	Verificación cruzada independiente (vector de estado) y transpilación a compuertas nativas para estimar profundidad en hardware.

Se trabajó en un entorno `conda` dedicado (`compu_cuantica`, Python 3.11, PennyLane 0.45, Qiskit 2.6, scikit-learn 1.9).

5.2. Verificación del circuito

El circuito se reconstruyó en Qiskit y se comparó con PennyLane para $L \in \{1, 3, 4\}$ con parámetros aleatorios y 20 muestras: la diferencia máxima entre probabilidades fue $\lesssim 5 \times 10^{-16}$, es decir, precisión de máquina. Transpilado a $\{R_z, \sqrt{X}, X, \text{CNOT}\}$, el modelo $L = 4$ tiene **96 compuertas** (16 CNOT) y **profundidad 36**.

5.3. Decisiones de diseño relevantes

- **4 qubits.** Equilibrio entre información (95 % de varianza) y costo de simulación.
- **Lectura por probabilidades de estados base** con temperatura entrenable: permite obtener las 7 salidas con una única medición en la base computacional, sin observables ni circuitos adicionales.

- **Escala entrenable α:** imita la parte lineal de una neurona y facilita adaptar el ancho de banda a cada característica.
- **Selección de época por F1 macro en validación**, nunca en prueba.
- **Tres semillas** de inicialización para medir la variabilidad inherente al paisaje no convexo.

6. Diseño experimental y métricas

Métricas. *Accuracy*; F1 macro (promedio no ponderado del F1 por clase; es la métrica principal por el desbalance), F1 ponderado; matriz de confusión y reporte por clase (precisión y exhaustividad).

Baselines clásicos (mismas particiones; hiperparámetros por defecto, sin ajustarlos en prueba):

- *Con la misma entrada que el QNN (4 componentes PCA):* centroides más cercanos (análogo clásico del *swap-test*), regresión logística, MLP pequeño de 6 neuronas (≈79 parámetros, capacidad comparable), SVM con kernel RBF, Random Forest y MLP 64–32.
- *Con las 16 características originales:* SVM-RBF, MLP 64–32 y Random Forest, para medir cuánto se pierde al comprimir a 4 qubits.

Ablaciones. (a) Profundidad $L \in \{1, 2, 4, 6\}$ con re-subida. (b) VQC convencional *sin* re-subida ($L = 4$, datos codificados solo en la primera capa). Una semilla, mismo presupuesto de entrenamiento.

Muestreo finito. Se evalúa el modelo ya entrenado con $S \in \{50, 200, 1000, 5000\}$ *shots* por muestra (3 repeticiones) sobre 1 000 granos de prueba, comparando con la evaluación exacta.

7. Resultados

7.1. Modelo cuántico

En las tres semillas el QNN ($L = 4$) obtiene en prueba **accuracy** $= 0{,}884 \pm 0{,}002$ y **F1 macro** $= 0{,}886 \pm 0{,}002$. La semilla elegida por validación (semilla 0) alcanza 0,887 y 0,888.

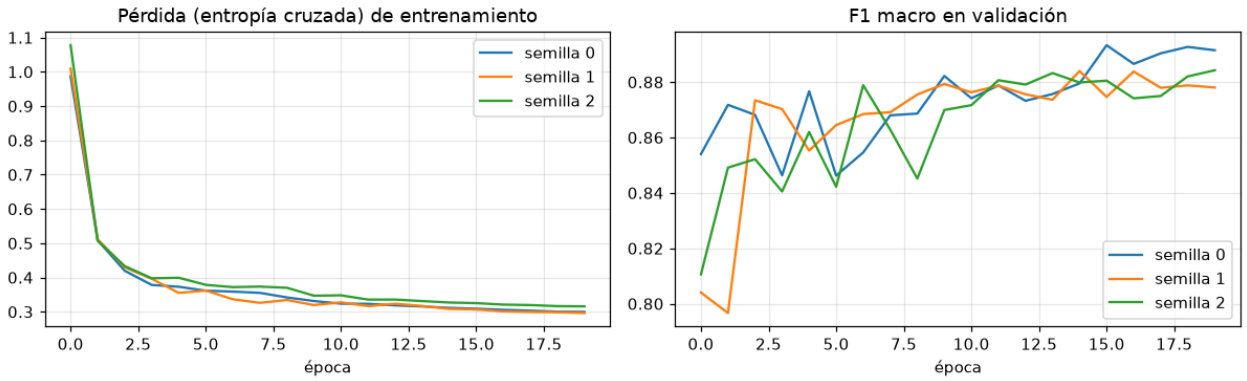


Figura 4: Entrenamiento de las tres semillas: pérdida (izquierda) y F1 macro en validación (derecha).

Tabla 1: Reporte por clase del QNN (semilla 0) en el conjunto de prueba.

Clase	Precisión	Exhaustividad	F1	Soporte
Barbunya	0.856	0.657	0.744	397
Bombay	0.994	0.987	0.990	156
Cali	0.794	0.883	0.836	489
Dermason	0.908	0.913	0.910	1064
Horoz	0.953	0.943	0.948	558
Seker	0.942	0.934	0.938	608
Sira	0.829	0.874	0.851	791
Macro	0.896	0.884	0.888	4063

7.2. Comparación con modelos clásicos

Tabla 2: Resultados en el conjunto de prueba (4 063 granos). El QNN aparece como media de 3 semillas.

Modelo	Entrada	Parámetros	Accuracy	F1 macro
QNN re-uploading $L = 4$	4 PCA (4 qubits)	65	0.884	0.886
Centroides más cercanos	4 PCA	–	0.804	0.810
Regresión logística	4 PCA	35	0.887	0.890
MLP 6 neuronas	4 PCA	79	0.885	0.887
Random Forest	4 PCA	–	0.889	0.894
MLP 64–32	4 PCA	2 631	0.890	0.894
SVM RBF	4 PCA	–	0.895	0.898
Random Forest	16 caract.	–	0.919	0.931
SVM RBF	16 caract.	–	0.924	0.936
MLP 64–32	16 caract.	3 399	0.926	0.937

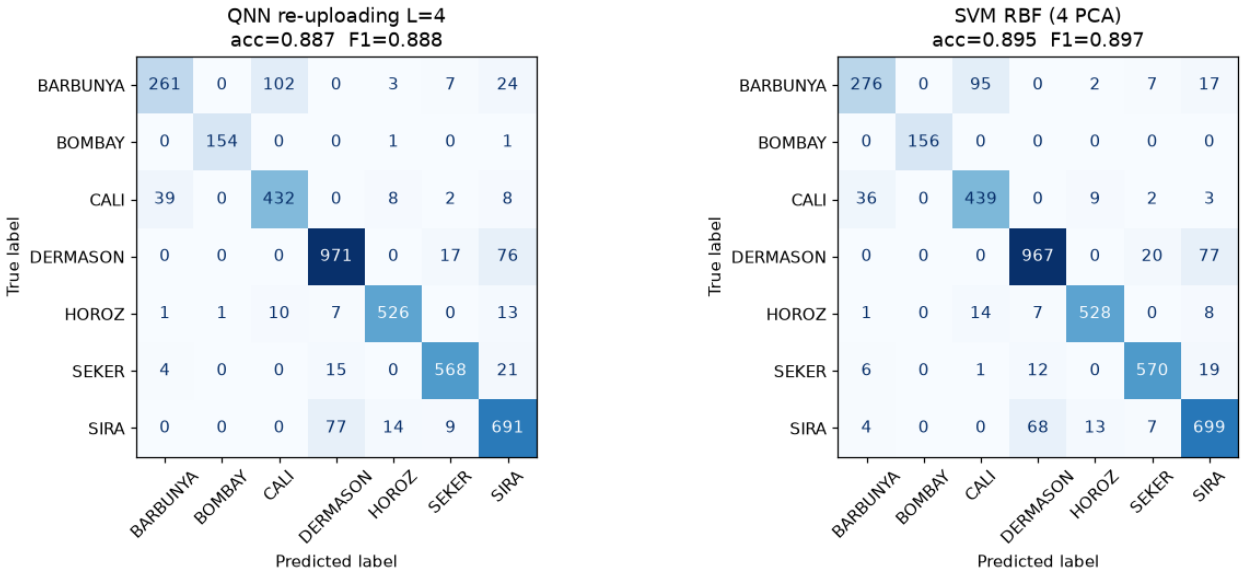


Figura 5: Matrices de confusión del QNN y del SVM-RBF (ambos con 4 componentes PCA). Los errores se concentran en los mismos pares de clases.

7.3. Ablaciones

Tabla 3: Ablación de arquitectura (semilla 0, prueba).

Configuración	Parámetros	Accuracy	F1 macro
$L = 1$, re-subida	17	0.611	0.455
$L = 2$, re-subida	33	0.863	0.858
$L = 4$, re-subida (principal)	65	0.887	0.888
$L = 6$, re-subida	97	0.886	0.888
$L = 4$, **sin** re-subida (VQC)	53	0.870	0.861

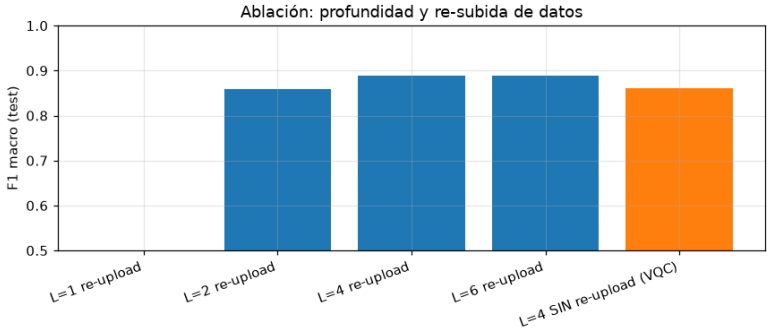


Figura 6: F1 macro en prueba para distintas profundidades y con/sin re-subida de datos.

7.4. Efecto del número de *shots* y costo

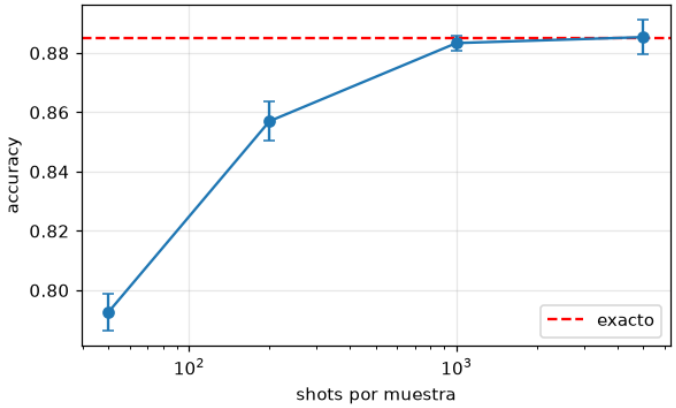


Figura 7: *Accuracy* del QNN entrenado al estimar p_k con S *shots*. La línea roja es la evaluación exacta (0,885 en esta submuestra).

Con 50, 200, 1 000 y 5 000 *shots* la *accuracy* es 0,793, 0,857, 0,883 y 0,885 respectivamente. El error estándar de una probabilidad estimada es $\sqrt{p(1-p)/S}$, por lo que resolver diferencias entre clases cercanas exige $S = O(1/\varepsilon^2)$.

Para *entrenar* en hardware con *parameter-shift* y $S = 1000$ se necesitarían $8532 \cdot 2 \cdot 65 \cdot 1000 \approx 1{,}1 \times 10^9$ *shots* por época y $\approx 2{,}2 \times 10^{10}$ en 20 épocas, frente a un único *backward pass* clásico; la inferencia sobre 4 063 granos cuesta $\approx 4 \times 10^6$ *shots*.

8. Discusión y conclusiones

1. **Competitividad.** Con 4 qubits y 65 parámetros, el QNN queda a ≈ 1 punto porcentual de F1 del mejor modelo clásico con la misma entrada (SVM-RBF) y empata con un MLP de capacidad comparable (79 parámetros). Con 4 063 muestras de prueba el error estándar de una *accuracy* cercana a 0,89 es $\approx 0{,}5\,\%$, por lo que la diferencia es marginal. Supera claramente al clasificador de centroides (0,810), lo que indica que la capacidad no lineal del circuito aporta.

2. **El cuello de botella es la entrada.** Todos los modelos con 4 componentes se estancan en $\approx$ 0,89–0,90; con las 16 características los clásicos llegan a 0,93–0,94 de F1. Comprimir a 4 componentes pierde información discriminante. Es una restricción *cuántica* real: codificación por ángulos implica un qubit por característica.

3. **Errores estructurales.** QNN y SVM confunden los mismos pares: Barbunya↔Cali y Dermason↔Sira, que se solapan en el espacio PCA; Bombay es casi perfecta (F1 $\approx$ 0,99). Barbunya, minoritaria, tiene la menor exhaustividad (0,66).

4. **La re-subida importa.** Con $L = 1$ el modelo es insuficiente; a partir de $L = 4$ se satura. Sin re-subida (mismo L) el F1 baja $\approx$ 2,7 puntos, consistente con la teoría de Fourier. Es una sola semilla: la magnitud es indicativa.

5. **Costo práctico.** En simulación el QNN tarda $\approx$ 150–220 s por entrenamiento frente a 0,3–10 s de los clásicos; en hardware, el entrenamiento y la inferencia requieren muchas mediciones y el rendimiento depende del presupuesto de *shots*.

6. **Ventaja cuántica: no.** En este problema un modelo clásico de 79 parámetros iguala al QNN y modelos con más información lo superan, entrenando mucho más rápido. Un espacio de Hilbert de dimensión 16 se simula trivialmente. El aporte es demostrar que un clasificador variacional compacto y poco profundo (profundidad nativa 36, 16 CNOT) resuelve un problema multiclase real con un rendimiento competitivo y caracterizar sus costos.

Limitaciones y trabajo futuro

Una sola partición train/test y tres semillas (una validación cruzada estratificada daría intervalos de confianza más sólidos); hiperparámetros del QNN no optimizados exhaustivamente; sin modelo de ruido de compuertas; no se implementó la variante de centroides cuánticos con *swap-test*. Como extensiones: más componentes PCA/qubits, lecturas con observables $\langle Z_i \rangle$, simulación con ruido (Qiskit Aer) y mitigación de errores.

9. Reproducibilidad

El cuaderno `Proyecto_Final_Semillas_QML.ipynb` se ejecuta completo (aprox. 25 minutos en CPU) con el kernel `Python (compu_cuantica)`. Todas las fuentes de aleatoriedad están fijadas (partición con `random_state=42`; semillas 0, 1 y 2 para el QNN; semilla del muestreo de *shots*). Si no encuentra `data/`, el cuaderno descarga el dataset de UCI.

Referencias

[1] M. Koklu e I. A. Özkan. *Multiclass classification of dry beans using computer vision and machine learning techniques*. Computers and Electronics in Agriculture, 174:105507, 2020. Dataset UCI *Dry Bean*, DOI 10.24432/C50S4B.

[2] A. Pérez-Salinas, A. Cervera-Lierta, E. Gil-Fuster y J. I. Latorre. *Data re-uploading for a universal quantum classifier*. Quantum, 4:226, 2020.

[3] M. Schuld, R. Sweke y J. J. Meyer. *Effect of data encoding on the expressive power of variational quantum-machine-learning models*. Phys. Rev. A, 103:032430, 2021.

[4] V. Havlíček et al. *Supervised learning with quantum-enhanced feature spaces*. Nature, 567:209–212, 2019.

[5] J. R. McClean et al. *Barren plateaus in quantum neural network landscapes*. Nature Communications, 9:4812, 2018.

[6] V. Bergholm et al. *PennyLane: Automatic differentiation of hybrid quantum-classical computations*. arXiv:1811.04968, 2018.

[7] M. Schuld, A. Bocharov, K. M. Svore y N. Wiebe. *Circuit-centric quantum classifiers*. Phys. Rev. A, 101:032308, 2020.